

מודלים לא לינאריים במחקר ביצועים --- תרגיל בית 5

26 במאי 2024

הנחיות:

- יש להגיש שני קבצים בלבד:

- קובץ PDF עם תשובה לשאלות וצלום מסך של קוד ופלטים.
- קובץ ZIP המכיל את כל קובצי הקוד אותם נדרשם כתוב.

שאלה 1

פונקציית מטריה שימושית בלימוד מוכנה מונחת היא $\mathbb{R} \rightarrow \mathbb{R}^{n+1}$: $l: l(\mathbf{w}, v)$ המוגדרת על-ידי

$$l(\mathbf{w}, v) = \frac{1}{N} \sum_{i=1}^N \log \left(1 + e^{b_i (\mathbf{w}^T \mathbf{a}_i + v)} \right)$$

כאשר $\mathbf{w} \in \mathbb{R}^n$, $v \in \mathbb{R}$ עבור $N \in \mathbb{N}$ הם וקטורים כלשהם ו- $b_1, b_2, \dots, b_N \in \{-1, 1\}$ קבועים ו- $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_N \in \mathbb{R}^n$ משתנים. הסבירו במלים מדוע l גזרה ברציפות והוכיחו שקבוע לפיש' של הגרדיינט של l הוא $\frac{1}{4N} \sum_{i=1}^N \left(\|\mathbf{a}_i\|^2 + 1 \right)$. הכוונה: אל ת חשבו את הקבוע ישרות, אלא השתמשו בטענות ודוגמה שראינו בתרגול. |

שאלה 2

תהי $\{\mathbf{x}_k\}_{k \geq 0}$ סדרה הנוצרת ע"י שיטת הגרדיינט עם חיפוש קווי מדויק לזרוע הפונקציה הריבועית $f(\mathbf{x}) = \mathbf{x}^T \mathbf{Q} \mathbf{x}$ עבור מטריצה $\mathbf{Q} \succ 0$. הוכיחו כי לכל $k \in \mathbb{N}$ מתקאים

$$f(\mathbf{x}_{k+1}) \leq \left(\frac{\lambda_{\max}(\mathbf{Q}) - \lambda_{\min}(\mathbf{Q})}{\lambda_{\max}(\mathbf{Q}) + \lambda_{\min}(\mathbf{Q})} \right)^2 f(\mathbf{x}^k).$$

הכוונה: השתמשו באישוין הבא (ללא הוכחה): אם $\mathbf{Q} \prec 0$ אז לכל $y \in \mathbb{R}^n$ מתקיים

$$\frac{(\mathbf{y}^T \mathbf{y})^2}{(\mathbf{y}^T \mathbf{A} \mathbf{y})(\mathbf{y}^T \mathbf{A}^{-1} \mathbf{y})} \geq \frac{4\lambda_{\max}(\mathbf{Q})\lambda_{\min}(\mathbf{Q})}{(\lambda_{\max}(\mathbf{Q}) + \lambda_{\min}(\mathbf{Q}))^2}$$

כמו כן, ניתן להניח כי $0 < \mathbf{x}_k^T \mathbf{Q} \mathbf{x}_k < 0$ לכל k .


שאלה 3

שאלה זו עוסקת בשחרור תמונה מטושטשת (Image Deblurring). תמונה היא מטריצה שבה כל רכיב מייצג פיקסל עם צבע לפי שיטת צבעים מסוימת (gray, plasma, etc.). למשל, הפקודות הבאות יוצרות את דגל שודיה:

```

A=[[1,2,1,1,1],[1,2,1,1,1],[2,2,2,2,2],[1,2,1,1,1],[1,2,1,1,1]]
A = np.array(A)
plt.imshow(A, cmap='plasma')
plt.show()

```



ניתן לייצג טשטוש תמונה כהעתקה לינארית עליה (למשל, צילום תוך כדי נשיפה). לצורך כך נתייחס לתמונה בתצורתה הוקטורית, המתקבלת ע"י שרשור عمודותיה לווקטור عمודה אחד. מכאן, פעולה הטשטוש של תמונה מקורית x ניתנת להצגה $Cx = Ax$. המטריצה A נקבעת מטריצת הטשטוש והוקטור b הוא התמונה המטושטשת. אנו מעוניינים למצוא את התמונה המקורית x (לא הטשטוש), ולכן נפתרו את בעיית הריבועים הפלותים הבאה:

$$\min_{\mathbf{x} \in \mathbb{R}^n} \left\{ f(\mathbf{x}) = \|A\mathbf{x} - b\|^2 \right\}$$

הוריידו את הקובץ blur.ipynb מאתר הקורס. אין צורך להבין כיצד פועלת פונקציה זו. הפקודות הבאות יוצרות תמונה ואת התמונה המטושטשת:

```

A,b,x = blur(256, 5, 1)
plt.figure(figsize=(6,6))
plt.imshow(x.reshape(256,256), cmap='gray')
plt.show()
plt.figure(figsize=(6,6))
plt.imshow(b.reshape(256,256), cmap='gray')
plt.show()

```

a. הפעילו את שיטת הגרדיינט עם חיפוש קווי מדויק על מנת לשחזר את התמונה הלא מטושטשת x . התמונה ההתחלתית היא תמונה האפסים. צרפו את הפלט המתקבל לאחר $1, 10, 100$ ו- 1000 איטרציות. (ניתן להשתמש בפונקציות מתרגיל הבית הקודם -- רק שמו לב לשנות את תנאי העצירה בהתאם). אין צורך לבדוק את נכונות הקלט. הניחו ש- A בעלת עמודות בת"ל.

b. ראיינו בכיתה שקבוע לפ██ץ של הגרדיינט של f הוא $(A^T A)^{-1} 2\lambda_{\max}$. הוכחו שגם קבוע לפ██ץ ההדוק (קטן) ביותר.

הכוונה: הראו שיש וקטורים עבורם האיזואון שקיים בהגדרת קבוע לפ██ץ הוא שווין. חיזרו על הסעיף הקודם עם גודל צעד קבוע $\frac{1}{L}$, כאשר L הוא קבוע לפ██ץ ההדוק ביותר של הפונקציה f . השתמשו בפונקציה `eigs` בשביל לחשב את L (זמן ההערכתה, חשבו את L והציבו את ערכו במשתנה, והימנו

מלחץ את L בכל איטרציה מחדש). איזו משלש הגישות מהירה יותר? איזו משלש הגישות נותנת תוצאה אינטואטיבית יותר?

ג. שיטת גרדיאנט מואצת (Accelerated Gradient) מושגה קצב התכנסות של $O\left(\frac{1}{k^2}\right)$, בעוד שזה של שיטת הגרדיאנט הוא $O\left(\frac{1}{\sqrt{k}}\right)$ (הvisorון הוא שהשיטה המואצת לא בטוח מוכנסת לנקודה סטציונרית). השיטה המואצת נראה כך:

```

set  $\mathbf{y}^1 := \mathbf{x}^0$  and  $t^1 = 1$ 
for  $k = 1, 2, \dots$  do:
     $\mathbf{x}^k = \mathbf{y}^k - \frac{1}{L} \nabla f(\mathbf{y}^k)$ 
     $t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}$ 
     $\mathbf{y}^{k+1} = \mathbf{x}^k + \frac{t^k - 1}{t^{k+1}} (\mathbf{x}^k - \mathbf{x}^{k-1})$ 
end for

```

כיתבו פונקציית python המופעלת באופן הבא:

```
x , fs , gs , ts = AG(f , gf , L , x0 , max_iter)
```

עבור f פונקציה בעלת גרדיאנט לישמי עם קבוע L . תנאי העזרה הוא max_iter איטרציות ומשמעות שאור המשתנים האחרים זהה לממה שמוגדר בשאלה 1 בתרגיל הבית הקודם.

ד. חזרו על סעיף א' עבור שיטת הגרדיאנט המואצת. איזו משלש השיטות נותנת תוצאה אינטואטיבית יותר?
בנוסף, צרפו תרשימים אחד עם ארבעה גרפים עבור ערכי פונקציית המטרה והזמן המمطلوب ל-1000 איטרציות עבור שיטת צעד קבוע ועבור שיטת הגרדיאנט המואצת. השתמשו בסולם לוגריטמי בציר $\text{ה-}y$. איזו משלש השיטות סימנה 1000 איטרציות מהר יותר? איזו משלש השיטות זקופה לפחות איטרציות בשליל להגעה לערך פונקציית מטרה נמוך יותר?

שאלה 4

בבואה איקון מקום של עצם מסוים (למשל, מקום נפילת רקטה על-סמן גורמי תצפית שונים) נתונים m מקומות של חישנים $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_m \in \mathbb{R}^n$ ומרחקים מוערכים $d_1, d_2, \dots, d_m \geq 0$ בין החישנים לבין העצם. כלומר, אם נסמן את מקום העצם ב- $\mathbf{x} \in \mathbb{R}^n$, אז אנו יודעים כי $\|\mathbf{x} - \mathbf{a}_i\| \approx d_i$ לכל $i = 1, 2, \dots, m$. לכן, דרך להעריך את מקום העצם $\mathbf{x} \in \mathbb{R}^n$ היא לפתור את בעיית האופטימיזציה הבאה:

$$\min_{\mathbf{x} \in \mathbb{R}^n} \left\{ f(\mathbf{x}) \equiv \sum_{i=1}^m (\|\mathbf{x} - \mathbf{a}_i\| - d_i)^2 \right\}$$

א. הסבירו (אין צורך בהוכחה מתמטית) מדוע פתרון בעיית אופטימיזציה זו אכן נותן הערכה עבור מיקומו האמיתי של העצם.

ב. הראו שתנאי האופטימליות $\nabla f(\mathbf{x}) = \mathbf{0}_n$ עבור $\mathcal{A} \notin \mathbf{x}$ שקול לתנאי

$$\mathbf{x} = \frac{1}{m} \left(\sum_{i=1}^m \mathbf{a}_i + \sum_{i=1}^m d_i \frac{\mathbf{x} - \mathbf{a}_i}{\|\mathbf{x} - \mathbf{a}_i\|} \right)$$

א. הראו שיטת נקודת השבת הבאה

$$x^{k+1} = \frac{1}{m} \left(\sum_{i=1}^m a_i + \sum_{i=1}^m d_i \frac{x^k - a_i}{\|x^k - a_i\|} \right)$$

היא שיטת גרדיאנט, תחת ההנחה ש- $x^k \notin \mathcal{A}$ לכל k . מהו גודל הצעד?

שאלה 5

א. תהי $A \in \mathbb{R}^n$ הפיכה ויהי $b \in \mathbb{R}^n$. יהיו $\Delta \in \mathbb{R}^n$ כך $\Delta \approx \Delta b$. נסמן Δx וב- Δx את הפתרונות של מערכות המשוואות b ו- Δb : $Ay = b$ ו- $A\Delta x = \Delta b$. הוכחו כי

$$\cdot \frac{\|\Delta x\|}{\|x\|} \leq \kappa(A) \frac{\|\Delta b\|}{\|b\|}$$

מהי המשמעות של אי-שוויון זה?

ב. נתונות הפונקציות $g(x) = \frac{1}{2}x^T G x$ ו- $f(x) = \frac{1}{2}x^T F x$ ו- $g: \mathbb{R}^n \rightarrow \mathbb{R}$ ו- $f: \mathbb{R}^n \rightarrow \mathbb{R}$ המוגדרות על-ידי עבורו

$$\cdot F = \begin{pmatrix} 2 & 2 & 3 \\ 2 & 5 & 5 \\ 3 & 5 & 7 \end{pmatrix}, \quad G = \begin{pmatrix} 10 & 8 & 9 \\ 8 & 13 & 11 \\ 9 & 11 & 15 \end{pmatrix}$$

נניח והפעלו את שיטת הגרדיינט למציאת מינימום של f ושל g עם גודל צעד קבוע מיטבי. נניח שתנאי העצירה הוא $\varepsilon \leq \|\nabla f(x)\|$. איזו ממשית הבניות צפוייה להתכנס מהר יותר עבור נקודת ההתחלתה (1000, 1000, 1000)? הסבירו את תשובתכם (תוכלו להשתמש ב-`python` לשבייל להימנע מלבצע חישובים ידניים, אך אין צורך להציג קוד).

שאלה 6 (איו חוגת הגשה -- בונוס 10 נקודות)
 נתונה $f: \mathbb{R}^n \rightarrow \mathbb{R}$ גזירה ברציפות, חסומה מרענן ובעל גרדיאנט לפשיטי עם קבוע L . נניח $\nabla^2 f(x) \succeq 0$ לכל $x \in \mathbb{R}^n$. תהי $\{x^k\}_{k \geq 0}$ הסדרה הנוצרת ע"י שיטת הגרדיינט עם גודל צעד קבוע $t \in (0, \frac{2}{L})$. נניח שלבעה $f(x^k) \rightarrow f^*$ קיימים פתרון ב- \mathbb{R}^n ונסמן $f^* = \min_{x \in \mathbb{R}^n} f(x)$. נניח שהסדרה $\{x^k\}_{k \geq 0}$ חסומה. הוכחו כי $\lim_{k \rightarrow \infty} f(x^k) = f^*$.

פונקציית מטרה שימושית בלמידה מוכנה מונחית היא $\mathbb{R}^{n+1} \rightarrow \mathbb{R}$: l : המוגדרת על-ידי

$$l(\mathbf{w}, v) = \frac{1}{N} \sum_{i=1}^N \log \left(1 + e^{b_i(\mathbf{w}^T \mathbf{a}_i + v)} \right)$$

כאשר $\mathbf{w} \in \mathbb{R}^n, v \in \mathbb{R}$ עבור $b_1, b_2, \dots, b_N \in \{-1, 1\}$ הם וקטורים כלשהם, $N \in \mathbb{N}$ הם וקטורים כלשהם, $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_N \in \mathbb{R}^n$ משתנים. הסבירו במלילים מדווק גיירה ברציפות והוכחו שקבוע לפ楔' של הגרדיינט של l הוא $\frac{1}{4N} \sum_{i=1}^N (\|\mathbf{a}_i\|^2 + 1)$.

הכוונה: אל תחשבו את הקבוע ישירות, אלא השתמשו בטענות ובדוגמה שראינו בתרגול.

$f_i(\mathbf{w}, v) = \log \left(1 + e^{b_i(\mathbf{w}^T \mathbf{a}_i + v)} \right)$

כגון נטה $f_i(\mathbf{w}, v) = \frac{1}{4N} \sum_{i=1}^N f_i(\mathbf{w}, v)$

$f(\mathbf{w}) = \frac{1}{4N} \sum_{i=1}^N f_i(\mathbf{w}, v_i)$

$L(\mathbf{w}, v) = \frac{1}{4N} \sum_{i=1}^N f_i(\mathbf{w}, v_i) \leq L(\mathbf{v}, v)$

$$F(x) = \log(1 + e^x) \text{ - } e \text{ - } F: \mathbb{R} \mapsto \mathbb{R}$$

$F(A_i \cdot x) = \int_{\mathbb{R}} f_i(x) d\mu$ גוררנו $L(\mathbf{w}, v) = \frac{1}{N} \sum_{i=1}^N F(A_i \cdot x)$

בנוסף $\|A_i\|_2^2 \cdot L_F \geq \frac{1}{N} \sum_{i=1}^N \|A_i\|_2^2 \cdot L_F$

לפ' F' מוגדרת $\subseteq h \in \mathbb{R} \mid |F''(x)| \leq h \quad \forall x \in \mathbb{R}$

$$F'(x) = \frac{e^x}{1 + e^x} \Rightarrow F''(x) = \frac{e^x(1 + e^x) - e^x(e^x)}{(1 + e^x)^2} = \frac{e^x}{(1 + e^x)^2}$$

$$F''(x) = \frac{e^x(1 + e^x) - 2e^x(1 + e^x)e^x}{(1 + e^x)^4} = \frac{e^x - e^{2x}}{(1 + e^x)^3} = \frac{e^x(1 - e^x)}{(1 + e^x)^3} = 0$$

$x = 0 \quad (\Leftarrow e^x = 1)$

$F''(x) \leq 0 \quad \forall x > 0$, $F''(t) \leq -\frac{1}{4}$. $\lim_{x \rightarrow \infty} F(x) = 0$

$$F''(x) \geq 0 \quad (\Leftarrow x \leq 0)$$

$$F'(0) = \frac{1}{4} \quad \text{and, near zero when } x=0 \quad \Rightarrow$$

$$\text{Since } F'(0) \geq 0 \quad |F'(x)| \leq \frac{1}{4} \quad \in \text{from zero is } \leq \frac{1}{4} \in$$

$$L_0 F := \frac{1}{4} \quad \text{Converges}$$

$$\|A_i\|_2^2 = \|a_i\|_2^2 + 1$$

$$\bullet \quad \frac{1}{4N} \sum_{i=1}^N (\|a_i\|_2^2 + 1) \in$$

נו.

$$f(x) = x^T Q x, \quad Q \in \mathbb{R}^{n \times n}, \quad Q \succ 0$$

. קיימת שיטה ליניארית t על מנת למצוא מינימום פונקציית $f(x)$.

כזכור כורטזיה $g(t)$ הינה פונקציה מוגדרת כ-

הנוכחות רצויים.

$$\begin{aligned} g(t) &= f(x_k - t_k d_k) = (x_k - t_k d_k)^T Q (x_k - t_k d_k) = \\ &= x_k^T Q x_k - 2 t_k d_k^T Q x_k + t_k^2 d_k^T Q d_k \end{aligned}$$

$$\Rightarrow g'(t) = 2 t_k d_k^T Q d_k - 2 d_k^T Q x_k$$

מטרד $0 - \delta$ מינימום של $g(t)$ מתקיים רק אם $d_k^T Q d_k = 0$.

$d_k = \nabla f(x_k)$ הוא נגזרת כירובית בנקודה x_k .

$$\Rightarrow d_k = \nabla f(x_k) = 2 Q x_k \Rightarrow Q x_k = \frac{d_k}{2}$$

$$\Rightarrow g'(t^*) = 2 t^* d_k^T Q d_k - 2 d_k^T Q x_k = 2 t^* d_k^T Q d_k - d_k^T d_k = 0$$

$$\Rightarrow t^* = \frac{d_k^T d_k}{2 d_k^T Q d_k}$$

$$t_k^* = \frac{d\kappa^T d\kappa}{2d\kappa^T Q d\kappa}$$

: δειγμα $\int k > N$

$$f(x_{k+1}) = x_{k+1}^T Q x_{k+1} = (x_k - t_k d_k)^T Q (x_k - t_k d_k) =$$

$$= x_k^T Q x_k - 2 t_k d_k^T \underbrace{Q x_k}_{\frac{1}{2} d_k} + t_k^2 d_k^T Q d_k \geq 0$$

$$= \mathbf{x}_k^T Q \mathbf{x}_k - t_k d_k^T d_k + t_k^2 d_k^T Q d_k$$

$$f(x_{k+1}) = x_k^T Q x_k - \frac{(d_k^T d_k)^2}{2 d_k^T Q d_k} + \frac{(d_k^T d_k)^2 \cdot (d_k^T Q d_k)}{(2 d_k^T Q d_k)^2} =$$

: סדרהijk3NL t_k^* ס'ג

$$= \mathbf{x}_k^T Q \mathbf{x}_k - \frac{(\mathbf{d}_k^T \mathbf{d}_k)^2}{2 \mathbf{d}_k^T Q \mathbf{d}_k} + \frac{(\mathbf{d}_k^T \mathbf{d}_k)^2}{4 \mathbf{d}_k^T Q \mathbf{d}_k}$$

$$= \mathbf{x}_k^T Q \mathbf{x}_k - \frac{(\mathbf{d}_k^T \mathbf{d}_k)^2}{4 \mathbf{d}_k^T Q \mathbf{d}_k} = \mathbf{x}_k^T Q \mathbf{x}_k \left(1 - \frac{1}{4} \cdot \frac{(\mathbf{d}_k^T \mathbf{d}_k)^2}{(\mathbf{d}_k^T Q \mathbf{d}_k) (\underbrace{\mathbf{x}_k^T Q Q^{-1} Q \mathbf{x}_k}_{\frac{1}{2} \mathbf{d}_k^T \mathbf{d}_k})} \right)$$

$$= x_k^T Q x_k \left(1 - \frac{y}{\gamma} \cdot \frac{(d_k^T d_k)^2}{(d_k^T Q d_k) (d_k^T Q^{-1} d_k)} \right)$$

וְאֵלֶיךָ יְהוָה נִזְמַן וְאֵלֶיךָ יְהוָה נִזְמַן:

$$\frac{(d^T d_k)^2}{(d^T Q d_k) (d^T Q^{-1} d_k)} \geq \frac{4 \lambda_{\max}(Q) \lambda_{\min}(Q)}{(\lambda_{\max}(Q) + \lambda_{\min}(Q))^2}$$

$$f(x_{k+1}) = x_k^T Q x_k \left(1 - \frac{4}{4} \cdot \frac{(d_k^T d_k)^2}{(d_k^T Q d_k)(d_k^T Q^{-1} d_k)} \right) =$$

$$= f(x_k) \left(1 - \frac{(d_k^T d_k)^2}{(d_k^T Q d_k)(d_k^T Q^{-1} d_k)} \right)$$

: סעיף 1.1(e) נגזר

$$f(x_{k+1}) = f(x_k) \left(1 - \frac{(d_k^T d_k)^2}{(d_k^T Q d_k)(d_k^T Q^{-1} d_k)} \right) \leq f(x_k) \left(1 - \frac{4 \lambda_{\max}(Q) \lambda_{\min}(Q)}{(\lambda_{\max}(Q) + \lambda_{\min}(Q))^2} \right) =$$





$$= f(x_k) \left(\frac{\lambda_{\max}^2(Q) + 2 \lambda_{\max}(Q) \lambda_{\min}(Q) + \lambda_{\min}^2(Q) - 4 \lambda_{\max}(Q) \lambda_{\min}(Q)}{(\lambda_{\max}(Q) + \lambda_{\min}(Q))^2} \right) =$$

$$= f(x_k) \left(\frac{\lambda_{\max}^2(Q) - 2 \lambda_{\max}(Q) \lambda_{\min}(Q) + \lambda_{\min}^2(Q)}{(\lambda_{\max}(Q) + \lambda_{\min}(Q))^2} \right) =$$

$$= f(x_k) \left(\frac{(\lambda_{\max}(Q) - \lambda_{\min}(Q))^2}{(\lambda_{\max}(Q) + \lambda_{\min}(Q))^2} \right)$$



FC - 2



```

def plot(i, x):
    plt.figure(figsize=(6,6))
    plt.imshow(x.reshape(256,256), cmap='gray')
    plt.title(f"exact quad where {i} iterations")
    plt.show()

usage: new *
def generic_grad(f, gf, x0):
    start_time = time.time() * 1000
    x, i = [x0], 0
    ts = [0, (time.time() * 1000 - start_time)]
    x.append(x[0] - exact_quad(f, x[0], gf(x0), AA))
    fs, gs = [f(x[0]), f(x[1])], [np.linalg.norm(gf(x[0])), np.linalg.norm(gf(x[1]))]
    for i in range(1000):
        gk = gf(x[i])
        t = exact_quad(f, x[i], gk, AA)
        x.append(x[i] - t * gk)
        fs.append(f(x[i+1]))
        gs.append(np.linalg.norm(gk))
        ts.append(time.time() * 1000 - start_time)
        if(i in [1,10, 100, 1000]):
            plot(i, x[len(x)-1])
def exact_quad(f, xk, gk, A):
    return (np.linalg.norm(gk) ** 2) / (((2 * np.linalg.norm(A.dot(gk)))**2))

```

```

#A = np.array([[1,2,1,1,1],[1,2,1,1,1],[2,2,2,2,2],[1,2,1,1,1],[1,2,1,1,1]])
A, b, x = blur( N: 256, band: 5, sigma: 1)
AA = A.T.dot(A)
f = lambda x: np.linalg.norm(A.dot(x) - b) ** 2
gf = lambda x: 2 * AA.dot(x) - 2 * A.T.dot(b)
#l = 2 * max(np.real(scipy.sparse.linalg.eigs(AA)[0]))
l = 1.9994981175712248
x0 = np.zeros(np.shape(b))
ls = generic_grad(f, gf, x0)

```

$$\|\nabla F(x) - \nabla F(y)\|_2 \leq 2 \cdot \lambda_{\max}(A^T A) \cdot \|x - y\|_2 \quad : \text{由题意} \quad (P_3)$$

$$\|\nabla F(x) - \nabla F(y)\|_2 = 2 \cdot \sigma_{\max}(A^T A) \cdot \|x - y\|_2 \leq e^{-\rho} \quad \forall x, y \in \mathbb{R}^n$$

$$\nabla F(x) = 2 \cdot A^T \cdot (Ax + b)$$

$$\|\nabla F(x) - \nabla F(y)\|_2 = \|2 \cdot A^T \cdot ((Ax + b) - (Ay + b))\|_2 =$$


$$\|2A^T A(x-y)\|_2 = \sqrt{2} \|A^T A(x-y)\|_2$$

$x, y \in \mathbb{R}^n$, $\lambda_{\min}(A^T A) - \delta > k_{\lambda, n}$ 且 $\|x\|_2 = \|y\|_2$


$$\|\nabla F(x) - \nabla F(y)\| \stackrel{?}{=} 2\|A^T A u\|_2 = 2 \cdot \lambda_{\max}(A^T A) \|v\|_2$$

```
def generic_grad_b(f, gf, x0, t):
    start_time = time.time() * 1000
    x, i = [x0], 0
    ts = [0, (time.time() * 1000 - start_time)]
    x.append(x[0] - t)
    fs, gs = [f(x[0]), f(x[1])], [np.linalg.norm(gf(x[0])), np.linalg.norm(gf(x[1]))]
    for i in range(1001):
        gk = gf(x[i])
        x.append(x[i] - t * gk)
        fs.append(f(x[i+1]))
        gs.append(np.linalg.norm(gk))
        ts.append(time.time() * 1000 - start_time)
        if(i in [1, 10, 100, 1000]):
            plot(i, x[len(x)-1])
#A = np.array([[1, 2, 1, 1, 1], [1, 2, 1, 1, 1], [2, 2, 2, 2, 2], [1, 2, 1, 1, 1], [1, 2, 1, 1, 1]])
A, b, x = blur(N: 256, band: 5, sigma: 1)
AA = A.T.dot(A)
f = lambda x: np.linalg.norm(A.dot(x) - b) ** 2
gf = lambda x: 2 * AA.dot(x) - 2 * A.T.dot(b)
#l = 2 * max(np.real(scipy.sparse.linalg.eigs(AA)[0]))
l = 1.9994981175712248
x0 = np.zeros(np.shape(b))
#ls = generic_grad(f, gf, x0)
lsd = generic_grad_b(f, gf, x0, 1/l)
```


exact quad where 1 iterations




exact quad where 10 iterations



exact quad where 100 iterations



exact quad where 1000 iterations



(9, J. 3)

گلچینی را برای داده های اسکن شده
نمایش کردن و تجزیه و تحلیل کردن

فرآنشی می باشد و این دسته از
آنالیز از پیشگیری از احتوای
دسته بندی شده است.

. ۲۱۱

```





def AG(f, gf, l, x0, max_iter):
    bstart_time = time.time() * 1000
    y, t = [x0], [0, 1]
    x = [x0, x0]
    gs = [np.linalg.norm(gf(y[0]))]
    fs = [f(y[0])]
    ts = [0, (time.time() * 1000 - bstart_time)]
    for k in range(1, max_iter):
        x.append(y[k] - [i/l for i in gf(y[k])])
        t.append((1 + np.sqrt(1 + 4 * t[k] ** 2)) / 2)
        y.append(x[k] + ((t[k] - 1) / t[k + 1]) * (x[k] - x[k - 1]))
        gs.append(np.linalg.norm(gf(y[k])))
        fs.append(f(y[k]))
        ts.append(time.time() * 1000 - bstart_time)
    if k in [1, 10, 100, 1000]:
        plt(k, x[len(x) - 1])
        plt.figure()
        plt.semilogy(*args: range(len(fs)), fs, label='fs')
        plt.semilogy(*args: range(len(ts)), ts, label='ts')
        plt.xlabel('Iterations')
        plt.ylabel('Values')
        plt.title('Values of fs and fs_noise against the number of iterations')
        plt.legend()
        plt.show()
    return x, fs, gs, ts

start_time = time.time() * 1000

x, fs, gs, ts = AG(f, gf, l, x0, max_iter=1000)

plt.figure()
plt.semilogy(*args: range(len(fs)), fs, label='fs')
plt.semilogy(*args: range(len(ts)), ts, label='ts')
plt.xlabel('Iterations')
plt.ylabel('Values')
plt.title('Values of fs and fs_noise against the number of iterations')
plt.legend()
plt.show()

```



4

1c

$$\min_{x \in \mathbb{R}^n} \left\{ f(x) = \sum_{i=1}^m (||x - a_i|| - d_i)^2 \right\}$$

וְנִזְמָן (בְּגַדְעָה) × 10¹³ נֶגֶת כְּלֹת מִזְמָן כְּלֹת נֶגֶת

בכמ"ז הורוד הילנא ר' היל כנ"ג כתה הנמוד והנואם

הנ' עיר ברכות נ-ו אגדה גודל צורה נ-ו (di).

$$\forall i : \|x - a_i\| - d_i \approx 0 \Rightarrow \|x - a_i\| \approx d_i$$

6

ג. סדר הזרעים:

$$\nabla f(x) = \sum_{i=1}^m 2 \cdot (\|x - a_i\| - d_i) \cdot \frac{x - a_i}{\|x - a_i\|} = 0$$

$$\Rightarrow 2 \sum_{i=1}^m (x - a_i - \frac{d_i(x-a_i)}{\|x-a_i\|}) = 0$$

$$\Rightarrow 2 \sum_{i=1}^m x_i - 2 \sum_{i=1}^m a_i = 2 \sum_{i=1}^m d_i \frac{(x-a_i)}{\|x-a_i\|}$$

$$\Rightarrow \sum_{i=1}^m x = \sum_{i=1}^m a_i - \sum_{i=1}^m d \cdot \frac{x-a_i}{\|x-a_i\|}$$

$$\Rightarrow \hat{x} = \frac{1}{m} \left[\sum_{i=1}^m a_i - \sum_{i=1}^m d_i \frac{x - a_i}{\|x - a_i\|} \right]$$

(2)

: e 1.1.1

$$\nabla f(x^k) = 2m x^k - 2 \sum_{i=1}^m a_i - 2 \sum_{i=1}^m d_i \frac{(x-a_i)}{\|x-a_i\|}$$

$$\begin{aligned} x^{k+1} &= \frac{1}{m} \left[\sum_{i=1}^m a_i - \sum_{i=1}^m d_i \frac{x-a_i}{\|x-a_i\|} \right] = \\ &= \frac{1}{m} \left[\frac{2mx^k - \nabla f(x^k)}{2} \right] = \\ &= x^k - \frac{\nabla f(x^k)}{2m} \end{aligned}$$

$$t_k = \frac{1}{2m} \quad \text{or} \quad \text{6th iteration value is } 1.5$$

$$\|\Delta\| \approx 0, \quad \Delta b = b + \Delta \quad \Delta, b \in \mathbb{R}^n \text{ ok } (S)$$

$$\frac{\|\Delta x\|}{\|x\|} \leq k(A) \cdot \frac{\|\Delta b\|}{\|b\|}, \quad \text{כלומר } \Delta x \text{proximal over } x \\ \Delta x = A^{-1}\Delta b \quad \therefore x = A^{-1}b \quad \text{בפי}$$

הוכיחו נרמזו $\|\Delta x\| \cdot \|b\| \leq k(A) \cdot \|\Delta b\| \cdot \|k\|$ בזאת

$$\overbrace{\overbrace{A^{-1}\Delta b}^{\frac{x}{\|x\|}} \cdot \underbrace{\overbrace{\Delta b}^{k\|x\|}}_{\geq 0}}^{\frac{x}{\|x\|}} \leq \|A\| \cdot \|A^{-1}\Delta b\| \cdot \overbrace{\underbrace{\|\Delta b\|}_{\|b\|} \cdot \|k\|}^{\|x\|}$$

$$\|\Delta x\| \cdot \|b\| = \|A^{-1}\Delta b\| \cdot \overbrace{\|\Delta b\|}_{\|b\|} \leq \|A\| \cdot \|A^{-1}\Delta b\| \cdot \|\Delta b\| \cdot \|k\| = \|A\| \cdot \|A^{-1}\| \cdot \|\Delta b\| \cdot \|k\| \cdot \|x\| \blacksquare$$

• תרנגולת גוזן ב

(Δ מוגדר כטבוק x ו b בזאת Δ מוגדר כטבוק $A^{-1}\Delta b$)

הנחיות אספנות מילויים בזאת Δ מוגדר כטבוק $A^{-1}\Delta b$

Γ_R מוגדר כטבוק Δ מוגדר כטבוק $A^{-1}\Delta b$ (זאת Δ מוגדר כטבוק $A^{-1}\Delta b$)

$$\lambda_{\max}(F) \approx 12.34 \quad \lambda_{\min}(F) \approx 0.48$$

$$\lambda_{\max}(L) \approx 31.7 \quad \lambda_{\min}(L) \approx 2.9$$

$$\text{cond}(L) \approx 10.91 \quad \text{ול } \text{cond}(F) \approx 25.5 \quad \Leftarrow$$

ה**תאורה** מוגדרת כטבוק L שקיים קבוצה S כך ש

• $\forall x \in S$ מתקיים $\|Lx\| \leq \lambda_{\max}(L) \|x\|$